

2.2 Физически-информированная адаптация домена

2.2.1 Введение

Алгоритм физически-информированной адаптации домена представляет собой модель переноса обучения (transfer learning), интегрированную с физическими законами. Этот подход предназначен для решения задач, где необходимо использовать знания, полученные из одной области, которая описывается физической моделью (source domain), для улучшения обучения в другой, целевой области (target domain), которая может иметь ограниченные данные или иные особенности.

2.2.2 Архитектура алгоритма

Блок-схема алгоритма на рисунке 2.2.1 описывает процесс обучения модели с использованием переноса обучения. Сначала происходит получение и подготовка данных исходного домена D_s . После этого создается модель f_s и обучается на этих данных. Затем выполняется дообучение (fine-tuning) модели f_t на данных целевого домена D_t , используя уже обученные веса модели f_s .




Рисунок 2.2.1 — Архитектура алгоритма физически-информированной адаптации домена

Различия в характеристиках данных исходного и целевого домена представлены в таблице 2.2.1.

Таблица 2.2.1 — Сходства и различия данных исходного и целевого доменов

Характеристика	Исходный домен	Целевой домен
Объем данных	Большой объем данных, что позволяет модели усвоить основные физические закономерности.	Объем данных может быть ограничен как числом доступных точек, так и диапазоном, в котором они располагаются.

Параметры системы	Данные исходного домена основаны на определенных физических параметрах, которые являются известными и могут отличаться от параметров целевого домена.	Параметры модели целевого домена неизвестны. Также может быть неизвестно, полностью ли модель исходного домена соответствует данным целевого домена.
Тип данных	Данные могут представлять собой временные ряды, пространственные распределения, измерения в разных точках пространства или времени.	
Шум и погрешности	Данные могут содержать шум, моделируемый как случайные отклонения от идеальной модели, что делает модель более устойчивой к реальным условиям эксплуатации.	

Пример данных исходного и целевого доменов для уравнения

$$\frac{dy(t)}{dt} + ay(t) = 0 \quad (2.3.1)$$

с решением

$$y(t) = y_0 e^{-at} \quad (2.3.2)$$

с параметрами $a_t \neq a_s, y_{0t} \neq y_{0s}$, где s обозначает исходный домен, а t – целевой, представлен на рисунке 2.2.2.




Рисунок 2.2.2 — пример данных исходного (зеленая линия) и целевого (синие точки) доменов

Обучение физически-информированной модели происходит следующим образом. Модель использует знания из области с большим количеством данных исходного физического закона для улучшения предсказаний в целевом домене с ограниченными данными.

Шаги обучения:

- обучение модели f_s на исходных данных D_s :
 - 1) создание и компиляция модели f_s ;
 - 2) обучение модели f_s на большом объеме исходных данных D_s , которые представляют собой сгенерированные данные на основе известного физического закона, что позволяет ей обучиться исследуемым физическим закономерностям;
- перенос знаний в целевую модель f_t : веса обученной модели f_s переносятся в модель f_t , т. е. модель f_t инициализируется весами f_s ;
- дообучение на известных данных целевого домена D_t :
 - 1) модель f_t создается с тем же оптимизатором, функцией потерь и конфигурацией слоев (включая функцию активации), что и f_s ;
 - 2) модель f_t дообучается на ограниченном наборе данных цели D_t , что позволяет модели адаптироваться к новым параметрам физического закона, характерным для целевой области.

После обучения показатели качества модели f_t сравниваются с показателями модели f_t^c , которая обучается в тех же условиях, что и f_t за тем лишь исключением, что модель f_t^c инициализируется случайными весами, а не обученными из f_s . В качестве одного из показателей качества может быть использована среднеквадратическая ошибка – RMSE.

2.2.3 Тестирование алгоритма

В рамках разработки алгоритма физически-информированной адаптации домена был проведен анализ эффективности модели f_t на решении (2.3.2) с различными параметрами для целевого и исходного доменов в сравнении с эффективностью модели f_t^c . Результаты работы f_t , когда данные D_t расположены на интервале $t_t \in [2; 3]$ приведены на рисунке 2.2.3, когда данные D_t расположены на интервале $t_t \in [0; 0,5] \cup [4,5; 5]$ – на рисунке 2.2.4. На представленных рисунках черной линией обозначены действительные значения, которые модели должны были предсказывать;

красным пунктиром обозначены значения, которые предсказала модель $f_t^{\hat{}}$; желтым пунктиром обозначены значения, которые были предсказаны моделью f_t ; синими точками обозначены данные, которые были доступны для f_t (для обучения) и $f_t^{\hat{}}$ (для дообучения); серым пунктиром обозначены данные домена источника (физического закона), на котором предварительно обучалась модель $f_t^{\hat{}}$. График сравнения отклонений, предсказанных моделями f_t и $f_t^{\hat{}}$ от истинных изображены на рисунках 2.2.5 и 2.2.5 для соответствующих интервалов. Оранжевая линия обозначает отклонения предсказанных значений от реальных, которые были получены с помощью $f_t^{\hat{}}$; зеленая линия обозначает отклонения f_t .




Рисунок 2.2.3 — Сравнение моделей f_t (красный пунктир) и $f_t^{\hat{}}$ (желтый пунктир) при $t \in [0; 0,5] \cup [4,5; 5]$




Рисунок 2.2.4 — Сравнение моделей f_t (красный пунктир) и $f_t^{\hat{}}$ (желтый пунктир) при $t \in [1,5; 3,5]$




Рисунок 2.2.5 — График ошибки f_t (желтая кривая) и f_t^i (зеленая кривая) относительно истинных значений при $t \in [0; 0,5] \cup [4,5; 5]$




Рисунок 2.2.6 — График ошибки f_t (желтая кривая) и f_t^i (зеленая кривая) относительно истинных значений при $t \in [1,5; 3,5]$

Также эффективность работы была проверена на полиномах, которые описывали исходный домен:

$$y_s(x) = x^7 + a_1 x^5 + a_2 x^3 + a_3 x, \quad (2.3.3)$$

и домен цели:

$$y_t(x) = x^7 + b_1 x^5 + b_2 x^3 + b_3 x + b_4 x^4 + b_5 x^2. \quad (2.3.4)$$

Отметим также, что определение истинных значений цели отличается от определения значений источника дополнительными слагаемыми. Оба полинома рассматривались на интервале $[-3; 3]$

Результаты модели f_t при данных D_t в интервале $x_t \in [-3; -2] \cup [2; 3]$ показаны на рисунке 2.2.7, а при наличии данных D_t на $x_t \in [-1; 1]$ представлены на рисунке 2.2.8.

Графики, сравнивающие отклонения предсказанных значений f_t и f_t^i от истинных, представлены на рисунках 2.2.9 и 2.2.10 для соответствующих интервалов.




Рисунок 2.2.7 — Сравнение моделей f_t (красный пунктир) и f_t^i (желтый пунктир) при $x_t \in [-3; -2] \cup [2; 3]$




Рисунок 2.2.8 — Сравнение моделей f_t (красный пунктир) и f_t^i (желтый пунктир) при $x_t \in [-1; 1]$




Рисунок 2.2.9 — График ошибки f_t (желтая кривая) и f_t^i (зеленая кривая) относительно истинных значений при $x_t \in [-3; -2] \cup [2; 3]$




Рисунок 2.2.10 — График ошибки f_t (желтая кривая) и f_t^i (зеленая кривая) относительно истинных значений при $x \in [-1; 1]$

Более подробные результаты работы алгоритма и их интерпретация представлены в отчете по верификации и валидации алгоритма № 11 в Приложении Б.

Следует отметить, что для того, чтобы модель смогла более качественно адаптироваться к новым условиям, необходимо предоставить ей больше информации об уникальных особенностях и характеристиках рассматриваемой системы. Чем больше данных и деталей модель получает о специфике системы, тем точнее она способна предсказать ее поведение и адаптироваться к изменениям в целевом домене. Этот факт связан с тем, что дополнительная информация позволяет модели учесть различные нюансы и факторы, влияющие на результаты, что в свою очередь повышает общую точность и надежность ее предсказаний. Эти факторы могут включать в себя информацию о локальных экстремумах, особенностях динамики, внешних воздействиях и других ключевых параметрах, определяющих поведение системы. Учет локальных

экстремумов позволяет модели точнее описывать сложные зависимости и выявлять критические точки, которые могут существенно повлиять на результат. Кроме того, знание о внешних воздействиях, таких как изменения окружающей среды, внешние шумы или специфические условия эксплуатации, дает модели возможность не только предсказывать поведение системы в стандартных условиях, но и адаптироваться к нестандартным ситуациям.

Однако, даже при ограниченном объеме доступных данных, в некоторых случаях модель все же демонстрирует способность успешно и качественно адаптироваться к целевому домену. Она может обеспечивать результаты с меньшей ошибкой по сравнению с моделью, которая не использовала методы переноса обучения, что подчеркивает эффективность и полезность переноса обучения, показывая, что даже без обширной информации о системе модель способна использовать ранее приобретенные знания для улучшения своей эффективности. Таким образом, применение техники физически-информированного переноса обучения для адаптации домена способствует повышению адаптивности модели и ее способности справляться с различными задачами в условиях ограниченной информации.

Физически информированный перенос обучения объединяет физические законы с методами машинного обучения и переноса знаний между различными задачами или доменами. В контексте IoT и умного производства рассматриваемый подход может значительно улучшить модели путем включения физических принципов и ускорения обучения на основе предыдущего опыта.

В IoT-системах используются многочисленные датчики, которые со временем могут выходить из строя или давать неточные данные. Физически информированные модели могут предсказывать ожидаемое поведение датчиков на основе физических законов (например, закон Ома для электрических датчиков). Перенос обучения позволяет адаптировать эти модели к разным типам или брендам датчиков без необходимости обучения с нуля.

В умном производстве важно предсказывать износ и отказы оборудования для предотвращения простоев. Алгоритм может использовать физические модели механического износа и переносить обученные модели на разные машины или производственные линии.

Среди преимуществ рассматриваемого подхода можно выделить следующие:

- включение физических законов в обучение моделей машинного обучения помогает им лучше обобщать новые данные или условия;

- использование переноса обучения и физической информации снижает количество данных, необходимых для обучения моделей;
- перенос ранее обученных моделей на новые задачи ускоряет процесс обучения и внедрения.